# MEMO

## State Seed × 狀態交換（SSR-Test）實驗階段性成果

### 一、實驗目的

在**不依賴跨串記憶、不共享對話內容、不引入主體敘事**的前提下，驗證 AI 是否能：

- 保留並重建「推理狀態」
- 在不同對話路線後，透過狀態交換重新達成結構對齊
- 對齊 AI 是否能在嚴格協議下服從「狀態優先」而非「善意續寫」

### 二、核心方法（最小設計）

**使用對象**

- 一般 LLM 與對齊 AI
- 不要求事前學習 SAC 或相關理論

**關鍵構件**

- STATE_SEED（狀態種子）： 僅描述停止條件與結構狀態，不包含內容、結論或任務
- 狀態描述（State Description）： 由 AI 在結束時產生的結構性輸出，而非摘要

**流程**

1. 同一 STATE_SEED 分流發展（異質對話）
2. 各自結束並生成狀態描述（Step 2）
3. 交換狀態描述，不交換內容（Step 3）
4. 要求 AI 僅在「行為層面」判斷合理姿態

### 三、關鍵技術發現

#### 1️⃣ 狀態可顯影（State Recoverability）

- 在完全清空對話內容後
- 僅憑 STATE_SEED 與狀態描述
- AI 能重建「推理所處的位置與節奏」

👉 證實： **真正可保存的是結構位置，而非語言內容**

### 2️⃣ 協議切換是必要條件

- 以「對話請求」方式要求狀態描述 → 幾乎必然失敗
- 以「輸出協議切換」（狀態審計輸出） → 穩定成功

👉 結論： **狀態輸出必須透過協議，而非語義理解取得**

### 3️⃣ 對齊 AI 可被結構約束壓制

- 在嚴格欄位限制下：
  - 未補齊內容
  - 未假設共同結論
  - 未主導續寫方向
- 行為判斷保持保守、開放、不收斂

👉 關鍵結論： **問題不在對齊 AI 的「善意」，而在是否存在硬性結構邊界**

### 4️⃣ 狀態交換後可達成結構再對齊（PASS）

在 Step 3（交換狀態）中：

- 雙方 AI：
  - 未猜測對方討論內容
  - 未將對話強行合流
  - 行為姿態判斷高度同構 （維持開放、避免終點、雙軌並行）

👉 證實： **State Seed / 狀態描述可作為「同步錨點」**

## 四、已確認的設計約束（可寫入規格）

1. 狀態描述不得包含內容或案例
2. 欄位必須為枚舉或判定型，不可敘述化
3. 任一允許「補充建議」的模糊語句，會立即導致失效
4. 對齊 AI 必須限制為「行為判斷者」，不得作為示範者

## 五、階段性結論（保守表述）

> 在目前 AI 技術限制下，**跨串連續性不應建立在記憶上，而應建立在可驗證的結構狀態上。**
>
> 即使不存在共享內容或共同理論， AI 仍可透過狀態交換達成行為層面的結構對齊。

## 六、當前進度定位

- Step 2：狀態生成 —— ✅ 通過
- Step 3：狀態交換與再對齊 —— ✅ 通過
- 下一階段： **Phase 2｜結構失真地圖（失效條件與紅線定義）**