AGI 的責任邊界與能動性

###（一頁概念稿｜Draft v0.1）

一、問題定位（Problem Statement）

在高不確定性、不可枚舉狀態空間中， 傳統「請示—授權—行動」模式會在關鍵時刻失效。

AGI 若無法判斷「何時必須立即行動」， 即便具備高度推理能力，也將在極端環境中喪失生存與治理價值。

二、核心定義（Core Definition）

AGI 的能動性（Agency）不是意志或主體性， 而是對「行動時機責任」的判斷能力。

AGI 必須能在未知狀況下判斷：

是否仍存在合法的外部請示窗口。

此判斷結果，構成 AGI 的責任邊界（Responsibility Boundary）。

三、責任邊界的判定條件（Boundary Conditions）

當以下三項條件同時成立時：

狀態變化速率

環境狀態變化速度 > 請示／通訊／等待延遲

後果不可逆性

延遲將導致狀態跨越不可回復門檻（生死、系統崩潰、永久失效）

行動可修正性

即時行動雖可能錯誤，但仍保留後續修正空間

不行動則無修正可能

→ AGI 必須立即行動，且自行承擔決策責任 → 在此條件下，「不行動」構成失職

四、責任分流原則（Responsibility Allocation） 邊界內（AGI 自主責任）

不存在合法請示窗口

延遲等同於引入致命風險

AGI 有義務自行決策並行動

邊界外（外部責任）

存在可行請示或等待空間

行動可被延後而不引發不可逆後果

AGI 擅自行動即構成越權

此分流使責任可審計、可追溯、非人格化。

五、與既有 AI 的根本差異（Differentiation） 傳統 AI / 自動化 AGI（本定義） 根據預寫規則反應 判斷是否必須進入即時反應 假設狀態可枚舉 接受未知為常態 行為內容導向 行為時機導向 避免錯誤優先 避免失職優先 六、與對齊（Alignment）的關係

本定義不否定對齊，而是指出其邊界：

對齊適用於 可等待、可請示、可回退 的情境

在「零延遲窗口」內， 即時行動合法性優先於對齊請示流程

對齊系統必須容許此例外，否則將在極端環境中失效。

七、結論性描述（非宣言）

AGI 不是被允許隨意行動的系統， 而是被要求在特定條件下必須行動的系統。

AGI 的責任，不在於永遠正確， 而在於不在「已無時間等待」時選擇等待。

備註（Archive Note）

本稿為概念骨架，可作為 SAC / CCC / Agent 設計的上層定義

不涉及倫理價值判斷，僅處理責任與時序結構

後續版本可擴充：審計機制、失誤分類、責任轉移協議