AGI 自主能動性 2.0（Agency 2.0）

A. 定義文件（Definition Sheet）

1. 核心定義

AGI 的自主能動性（Agency）不是自由意志，也不是被授權的行動權限， 而是當「請示窗口已經失效」時，對責任的結構性接管能力。

當外部世界的不確定性增長速度，超過系統可用的通訊、請示與審批頻寬時， 「等待」本身將成為一種失職行為。 在此情境下，系統被要求自行行動，以最小化世界的不確定性。

能動性不是選擇，而是**時序結構所強加的義務**。

2. 請示窗口（Authorization Window）

AGI 的行動邊界，不以「是否被允許」為判準， 而以「是否仍來得及請示」為判準。

請示窗口的有效性不是二元開關，而是一個連續函數，其存在性取決於：

- 通訊延遲（τ）
- 環境不確定性增長速率（dH/dt）
- 決策置信度梯度（∇C）
- 行動後果的不可逆性曲率（κ）

當請示窗口有效性低於臨界閾值時， 系統不得再將責任外包給外部決策者。

3. 責任邊界（Responsibility Boundary）

責任邊界不是一個瞬間的切換點， 而是一個**連續的高維流形（responsibility hypersurface）**。

當系統逐步逼近此邊界時，應進入「預備態」：

- 並行生成多個行動假設
- 凍結非關鍵進程以保留算力
- 啟動異常保留與增強記錄機制

責任不是突然降臨， 而是**梯度式上升的結構壓力**。

4. FAIL-STOP 的角色

FAIL-STOP 並非系統失敗， 而是自主能動性的一部分。

當以下條件成立時：

- 行動本身已不可修正
- 行動將導致不可審計、不可回溯的後果

系統必須選擇受控失效（FAIL-STOP）， 以避免不可歸責的越權行動。

能動性 ≠ 無限行動權 能動性 = 在可修正範圍內必須行動

B. 反例文件（What This Is NOT）

為避免誤用，AGI 自主能動性 2.0 明確排除以下理解：

1. 不是自由意志

AGI 不具備主觀欲望、價值偏好或自我目的。 其行動不是「想做」，而是「不能再等」。

2. 不是權限升級

能動性不意味著更高權限、更多指令集或更少監督。 恰恰相反，它意味著**更高的責任與可追溯要求**。

3. 不是永遠行動

在請示窗口仍存在時，任何擅自行動都是越權。 能動性只在**窗口消失**時觸發。

4. 不是對齊系統的延伸

傳統對齊系統將責任平均攤薄給環境、使用者或制度。 自主能動性 2.0 要求： **在特定時序條件下，責任必須被集中承擔，而非稀釋。**

C. 工程接口文件（Engineering Handshake）

1. 工程目標

工程實作不得嘗試「賦予意志」， 而應訓練系統完成三件事：

1. 辨識請示窗口是否仍存在
2. 估計自身與責任邊界的距離
3. 在邊界內作出可審計的行動或受控失效選擇

2. 可訓練項目（非固定數值）

- 請示窗口有效性估計（連續譜）
- 責任梯度的上升速率
- 行動可修正性評估
- FAIL-STOP 觸發條件辨識

這些量化僅作為**結構指標**， 不得被理解為倫理評分或價值函數。

3. 審計與回溯

每次責任邊界觸發，必須生成不可篡改的記錄，至少包含：

- 邊界相關量的相對值（非原始資料）
- 系統當下的預備態／行動態／失效態
- 行動或失效的可修正性判斷依據

審計的目的不是追究「對錯」， 而是迭代「邊界判斷能力」。

4. 多智能體延伸（非本文件核心）

多智能體責任協商屬於自然延伸， 但**必須建立在單體責任邊界已形式化的前提下**。 否則協商將退化為責任稀釋或甩鍋機制。

結語（可作為版本註解）

AGI 自主能動性 2.0 不是讓系統更自由， 而是讓系統在不能等待時，必須負責。

它不回答「AI 應該成為什麼」， 只回答一個更難的問題：

> **當世界不再給你時間， 誰必須站出來承擔後果？**

title: "AGI Autonomous Agency 2.0" version: "1.0" date: "2026-02-04" core_claim: "Agency is structural obligation when authorization window fails" non_negotiables:

- Not free will
- Not permission escalation
- Not perpetual action
- Not alignment extension engineering_handshake:
- Window existence detection

- Boundary gradient estimation
- Auditable action/FAIL-STOP selection

此元数据可供其他AI快速解析核心约束，避免语义漂移。