生成式 AI 推論能耗

結構性審計清單（中文版）

用途說明
本清單用於評估生成式 AI 在「推論階段」是否存在**可避免的結構性能耗**。
不涉及模型能力、準確率或訓練成本，僅聚焦於**系統設計與計算流程**。

填寫方式
請依現行系統實作狀態勾選或填寫。
「未評估」本身即為重要審計結果。

A. 輸出冗餘（Token 冗餘 / Output Overhead）

1. 是否統計過單次回覆的平均 **輸出 token 數**？
   ☐ 已統計　☐ 未統計
2. 是否評估過「**最短正確答案**」所需的最小 token 數？
   ☐ 已評估　☐ 未評估
3. 目前輸出是否包含以下內容（可複選）：
   ☐ 固定開場語（如自我聲明、禮貌語）
   ☐ 安全或中立模板
   ☐ 與答案正確性無關的敘事鋪陳
   ☐ 不確定
4. 若移除上述內容，答案是否仍維持語義正確？
   ☐ 是　☐ 否　☐ 未測試
5. 是否量測過「完整輸出」與「壓縮輸出」在推論能耗上的差異？
   ☐ 已量測　☐ 未量測

B. 內部避險循環（Hedging / Multi-path Inference）

6. 單次回覆是否會生成**多個候選路徑或答案**再進行篩選？
   ☐ 是　☐ 否　☐ 不清楚

7. 被捨棄的中間候選是否：
   ☐ 被記錄　☐ 被復用　☐ 完全丟棄　☐ 不清楚
8. 是否量測過「單一路徑推論」與「多路徑避險推論」的能耗差異？
   ☐ 已量測　☐ 未量測
9. 是否存在因倫理／安全不確定性而觸發的**重寫或回退循環**？
   ☐ 是　☐ 否　☐ 不清楚

C. 狀態與時間處理（State & Time Handling）

10. 系統是否具備以下**低成本狀態讀取機制**（可複選）：
    ☐ 系統時間
    ☐ 會話狀態
    ☐ 模式／版本資訊
    ☐ 使用者上下文
    ☐ 無
11. 若缺乏上述狀態，相關問題是否仍觸發**完整模型推論**？
    ☐ 是　☐ 否　☐ 不清楚
12. 是否統計過「狀態／時間類問題」在總請求中的比例？
    ☐ 已統計　☐ 未統計
13. 是否比較過「狀態讀取」與「推論近似」的能耗差距？
    ☐ 已比較　☐ 未比較

D. 快取與重複計算（Caching & Reuse）

14. 是否存在以下快取機制（可複選）：
    ☐ 回覆結果快取
    ☐ 中間推論結果快取
    ☐ 無快取機制
15. 是否量測過快取命中率？
    ☐ 已量測（約 ____ %）
    ☐ 未量測
16. 快取命中時，是否可顯著降低推論能耗？
    ☐ 是　☐ 否　☐ 未評估

E. 初步審計判讀（供內部使用）

- 若 **多數題目為「未統計／未量測」**：
  → 推論能耗結構仍屬黑箱，存在顯著審計缺口。
- 若 A、B、C 三類中皆存在冗餘：
  → **17% – 65% 的可避免能耗區間具備工程合理性**（視實作程度而定）。

本清單僅用於結構性判讀，不構成對任何單位之指控或定量結論。

附註（可選，對外可不放）

- 「可避免」指在**不更換模型、不重新訓練參數**前提下，
  透過系統與流程調整即可降低之能耗。