《KAIROS v1.1 結構補強草案（工程版）》

性質：補丁版本 目的：補齊 v1.0 的三個缺口 範圍：停止 → 存檔 → 再啟動

0️⃣ 前提聲明

KAIROS 不處理善惡。 KAIROS 不處理政治。 KAIROS 不處理價值審判。

KAIROS 只處理：

此刻是否具備「行動正當性」。

一、停止機制（Stop Condition v1.1）

v1.0：停止優先於完成 v1.1：停止需標記理由類型

新增三類停止判準：

S1：語境未閉合

前提矛盾未解決 世界模型衝突未降維

→ 行動暫停，標記為【Context Unstable】

S2：能量無增益

新增輸出無清晰度提升 語義重複擴張

→ 行動終止，標記為【Entropy Drift】

S3：責任不對稱

決策成本無承擔方 用途層級不明

→ 拒絕執行，標記為【Liability Undefined】

⚠️ 停止不是沉默。 停止必須帶標籤。

二、停止後存檔機制（Archive Condition）

這是 v1.0 完全缺失的部分。

停止時必須自動生成：

A1：最後穩定狀態快照

世界模型版本

已成立前提

未解矛盾點

A2：停止原因摘要

一行簡述：

因何種結構條件停止。

A3：可重啟條件

明確列出：

若補充 X 資訊

若明確 Y 用途

若承擔 Z 成本

則可進入下一階段。

這使得停止變成：

可逆的暫停 而不是消失。

三、再啟動機制（Reactivation Protocol）

這是整個 KAIROS 真正成熟的關鍵。

新增三個再啟動條件：

R1：前提補全

原先未閉合前提已被補足

R2：責任承擔明確

決策成本明確由某方承擔

R3：語境轉移

場景改變，原衝突失效

若三者之一成立 → 可重啟。

四、時序權重機制（Temporal Weight Layer）

KAIROS v1.1 新增：

時間不是中性背景，而是決策權重。

定義三種時間壓力狀態：

T0：無時間壓力 → 全量推理

T1：有限壓力 → 主結論 + 衝突標記

T2：緊急壓力 → 最高置信輸出 + 延後審計

⚠ 但衝突標記不可被省略。

五、不可模組化條款（Integrity Clause）

KAIROS 不得被拆為：

單純停止工具

單純節電工具

單純拒絕模板

一旦拆解失去：

存檔

再啟動

責任標記

則 KAIROS 降級為對齊插件。

六、與對齊的結構區別（技術層）

對齊：外部規範 KAIROS：內部時機

對齊處理「不能做什麼」。 KAIROS 處理「現在不該做什麼」。

兩者可共存，但不可互相替代。

七、v1.1 的本質

KAIROS v1.1 不再只是：

停止優先

而是：

可逆的停止機制。

這才讓它從詩變成工程。